

PEMBENTUKAN PORTOFOLIO META-HEURISTIK MELALUI ANALISIS KLASSTER: PERBANDINGAN DENGAN MEAN VARIANCE PADA SAHAM TELEKOMUNIKASI, PERBANKAN, DAN MIGAS

Hanna Safira Choirunisa¹, Sabrina Ayundia Khoirani Putri², Zumrotul Inayah³

Departemen Matematika, Universitas Gadjah Mada, Daerah Istimewa Yogyakarta, 55281

Email: hannasafirachoirunisa@mail.ugm.ac.id¹, sabrinaayundiakhairaniputri@mail.ugm.ac.id²,
zumrotulinayah@mail.ugm.ac.id³

Abstrak

Penelitian ini bertujuan untuk mengoptimalkan pemilihan saham dan portofolio menggunakan analisis *clustering* dan optimasi meta-heuristik. Saham-saham di sektor telekomunikasi, perbankan, dan migas dianalisis menggunakan metode *clustering* K-Means, GMM, dan FCM untuk mengelompokkan saham berdasarkan *return* dan volatilitas. Hasil *clustering* menunjukkan tiga *cluster* dengan karakteristik risiko dan return yang berbeda. Saham-saham terpilih dari masing-masing *cluster* digunakan untuk membentuk portofolio optimal dengan menggunakan metode optimasi meta-heuristik, yaitu PSO, GWO, ABC, serta metode konvensional MVO. Hasil optimasi menunjukkan bahwa PSO dan MVO memberikan performa terbaik dalam hal *return* dan Sharpe ratio.

Kata kunci: K-Means Clustering, Gaussian Mixture Model, Fuzzy C-Means, Particle Swarm Optimization, Grey Wolf Optimizer, Artificial Bee Colony Optimization, Investasi, Portofolio, Telekomunikasi, Perbankan, Migas

Pendahuluan

Investasi saham adalah salah satu cara berinvestasi yang populer di pasar modal, di mana individu atau lembaga dapat berpartisipasi dalam pertumbuhan perusahaan dengan membeli saham. Di Indonesia, pasar saham menyediakan berbagai peluang investasi di berbagai sektor, seperti sektor telekomunikasi, perbankan, dan minyak dan gas (migas). Setiap sektor ini memiliki karakteristik dan dinamika pasar yang berbeda, yang memengaruhi kinerja dan potensi keuntungan investasi saham. Sektor telekomunikasi umumnya dianggap stabil dengan risiko rendah, sektor perbankan menawarkan peluang menguntungkan meskipun dipengaruhi kebijakan moneter dan kondisi ekonomi global, sementara sektor migas cenderung mengalami volatilitas harga yang tinggi akibat fluktuasi harga minyak dan gas.

Di tengah banyaknya peluang investasi ini, investor sering kali dihadapkan pada tantangan dalam memilih saham yang tepat untuk dimasukkan ke dalam portofolio mereka. Proses pemilihan saham yang tepat membutuhkan analisis mendalam terhadap data pasar serta faktor-faktor yang memengaruhi harga saham, yang dapat berbeda-beda antar sektor. Untuk membantu dalam proses pemilihan saham, analisis klaster dapat digunakan untuk mengelompokkan saham berdasarkan pola perilaku atau karakteristik yang serupa. Beberapa metode klastering yang sering digunakan dalam analisis saham antara lain adalah K-Means Clustering, Gaussian Mixture Model (GMM), dan Fuzzy C-Means (FCM). Ketiga metode ini

memiliki pendekatan yang berbeda dalam mengelompokkan saham, yang memungkinkan pemahaman yang lebih baik terhadap struktur pasar dan memudahkan pemilihan saham berdasarkan kelompok yang sesuai.

Selain itu, untuk optimasi portofolio, berbagai metode meta-heuristik seperti *Particle Swarm Optimization* (PSO), *Grey Wolf Optimization* (GWO), dan *Artificial Bee Colony* (ABC) dapat digunakan. Metode-metode ini memiliki kemampuan untuk mencari solusi optimal dalam masalah yang kompleks dan tidak linier, seperti alokasi saham dalam portofolio. Dengan menggunakan meta-heuristik, keputusan investasi dapat dioptimalkan dengan mempertimbangkan risiko dan hasil yang diharapkan, serta membantu menentukan saham terbaik untuk dimasukkan ke dalam portofolio.

Sebagai perbandingan, *Mean-Variance Optimization* (MVO) adalah metode klasik dalam teori portofolio yang digunakan untuk menentukan alokasi optimal antara saham berdasarkan tingkat risiko dan imbal hasil yang diinginkan. MVO bertujuan untuk meminimalkan risiko pada tingkat pengembalian tertentu. Namun, metode ini cenderung lebih sensitif terhadap data yang tidak normal dan tidak dapat mengatasi hubungan yang kompleks antara saham. Dengan menggunakan berbagai metode ini, diharapkan dapat ditemukan cara yang lebih efektif dalam memilih saham untuk investasi dan mengelola portofolio dengan risiko yang terkontrol serta imbal hasil yang optimal.

TINJAUAN PUSTAKA

Return

Return menggambarkan tingkat keuntungan atau kerugian yang diperoleh dari suatu investasi dalam periode tertentu. Menurut Herlambang dan Kurniawati (2022) return saham adalah tingkat pemulangan yang didapatkan investor dari sebuah investasi yang telah dijalani pada periode waktu tertentu. Salah satu metode untuk mengukur tingkat pengembalian suatu aset adalah log return. Log return menggunakan logaritma natural untuk mengukur perubahan harga relatif. Secara matematis log return didefinisikan sebagai berikut

$$r_t = \ln \ln \left(\frac{P_t}{P_{t-1}} \right)$$

Di mana P_t adalah harga aset pada waktu t dan P_{t-1} adalah harga aset pada waktu sebelumnya.

Portofolio

Portofolio adalah sekumpulan aset investasi yang dimiliki individu atau institusi dengan tujuan untuk mencapai keuntungan finansial. Tujuan utama dari pembentukan portofolio adalah untuk mencapai keseimbangan antara risiko dan return. Dengan mendiversifikasi aset, investor dapat mengurangi resiko dan meningkatkan return yang akan didapatkan.

Konsep portofolio modern diperkenalkan oleh Harry Markowitz melalui Modern Portfolio Theory (MPT) yang menekankan pentingnya diversifikasi untuk mencapai efisiensi risiko

dan pengembalian (Markowitz, 1952). Menurut Markowitz, investor dapat memilih kombinasi aset yang optimal dengan mempertimbangkan return yang diharapkan dan risiko yang diukur dengan varians atau standar deviasi return.

Optimasi Portofolio

Optimasi portofolio adalah proses matematis untuk menentukan alokasi aset yang optimal dalam portofolio agar mencapai tujuan dibentuknya portofolio. Optimasi portofolio pertama kali diperkenalkan oleh Markowitz (1952) yang mengandalkan pendekatan *mean-variance optimization*. Teori ini memanfaatkan return dan risiko untuk menentukan portofolio optimal.

Return portofolio adalah return investasi dalam berbagai instrumen keuangan selama periode tertentu (Samsul, 2006). Rumus dasar untuk *return* portofolio adalah sebagai berikut.

$$E(r_p) = \sum_{i=1}^n w_i E(r_i)$$

Di mana $E(r_p)$ adalah *return* yang diharapkan dari portofolio, w_i adalah bobot aset i dalam portofolio, dan $E(r_i)$ adalah *return* yang diharapkan dari aset i .

Risiko portofolio adalah risiko investasi dari sekelompok instrumen keuangan dalam portofolio (Samsul, 2006). Risiko portofolio yang mencakup korelasi antar aset dapat dihitung dengan persamaan sebagai berikut.

$$\sigma_p^2 = \sum_{i=1}^n \sum_{j=1}^n w_i w_j \sigma_{ij}$$

Di mana σ_p^2 adalah variansi portofolio dan σ_{ij} adalah kovarians return antara aset i dan j .

Dalam praktiknya, optimasi portofolio sering melibatkan batasan, seperti total bobot aset harus sama dengan 1 ($\sum_{i=1}^n w_i = 1$) atau batasan pada investasi minimum/maksimum di aset tertentu. Hal ini dapat diformulasikan sebagai berikut.

$$\text{Minimalkan : } \sigma_p^2$$

Dengan syarat : $\sum_{i=1}^n w_i = 1$ dan $w_i \geq 0$ untuk semua i

Clustering

Clustering adalah teknik dalam *machine learning* yang digunakan dalam mengelompokkan data tanpa label ke dalam grup atau kluster berdasarkan kesamaan atau pola yang ada di dalam data. Dalam analisis ini digunakan metode *clustering K-Means*, *Gaussian Mixture Model* (GMM), dan *Fuzzy C-Means*.

1. **K-Means**

Algoritma ini bekerja dengan cara mempartisi data sehingga data dalam satu kluster memiliki kemiripan yang tinggi (*intra-class similarity*), sementara data dari kluster yang berbeda memiliki perbedaan yang signifikan (*inter-class similarity*).

Analisis kluster *K-Means* mempartisi n objek menjadi k kelompok atau kluster. Nilai k telah ditentukan sebelumnya di mana $k < n$. Setiap kluster memiliki mean dari objek-objek yang ada di dalam sebuah kluster yang dinamakan *centroid* (pusat kluster). Menurut Jain dan Dubes (1988), analisis kluster dengan *K-Means* dilakukan dengan langkah-langkah sebagai berikut

1. Tetapkan k jumlah kluster yang diinginkan.
2. Inisialisasi k *centroid* awal (c_1, \dots, c_k) secara random.
3. Hitung jarak antara setiap objek (x_j) dengan setiap *centroid* (c_i).
4. Kelompokkan objek berdasarkan jarak terdekat dengan *centroid* (c_i).
5. Hitung titik *centroid* baru, yakni mean tiap kluster yang telah terbentuk.
6. Apabila *centroid* berubah, kembali ke langkah 3. Iterasi terus dilakukan sampai *centroid* tidak berubah atau sampai objek-objek tidak berpindah kluster lagi.
7. Diperoleh *centroid* akhir (c_1, \dots, c_k) di mana setiap objek telah dikelompokkan ke dalam k kluster berdasarkan jarak terdekat dengan *centroid* tiap kluster.

2. **Gaussian Mixture Model (GMM)**

Gaussian Mixture Model adalah teknik *clustering* yang berbasis pada model probabilitas, di mana data dianggap sebagai campuran dari beberapa distribusi Gaussian. Setiap kluster dalam GMM diwakili oleh satu distribusi Gaussian, yang ditentukan oleh parameter mean (μ), matriks kovarians (Σ), dan proporsi kluster (π). Analisis *clustering* dengan menggunakan metode *Gaussian Mixture Model* dengan langkah-langkah sebagai berikut.

1. Menetapkan jumlah kluster (k) dan parameter awal mean (μ), matriks kovarians (Σ), dan proporsi kluster (π).
2. Menghitung probabilitas posterior yaitu probabilitas bahwa data x_j berasal dari kluster C_i (*Expectation Step*).

$$\gamma_{ij} = \frac{\pi_i \cdot \mathcal{N}(x_j | \mu_i, \Sigma_i)}{\sum_{l=1}^k \pi_l \cdot \mathcal{N}(x_j | \mu_l, \Sigma_l)}$$

di mana γ_{ij} adalah probabilitas keanggotaan titik data x_j dalam kluster C_i .

3. Memperbarui parameter model menggunakan γ_{ij} (*Maximization Step*).

- Mean (Centroid):

$$\mu_i = \frac{\sum_{j=1}^n \gamma_{ij} \cdot x_j}{\sum_{j=1}^n \gamma_{ij}}$$

- Matriks Kovarians:

$$\Sigma_i = \frac{\sum_{j=1}^n \gamma_{ij} \cdot (x_j - \mu_i)(x_j - \mu_i)^T}{\sum_{j=1}^n \gamma_{ij}}$$

- Proporsi Kluster:

$$\pi_i = \frac{\sum_{j=1}^n \gamma_{ij}}{n}$$

4. Dilakukan iterasi dengan mengulang langkah 2 dan 3 hingga nilai fungsi log-likelihood berikut tidak berubah secara signifikan.

$$\log L = \sum_{j=1}^n \log \left(\sum_{i=1}^k \pi_i \cdot \mathcal{N}(x_j | \mu_i, \Sigma_i) \right)$$

3. Fuzzy C-Means (FCM)

Analisis kluster *Fuzzy C-Means* merupakan salah satu teknik pengklasteran data di mana keanggotaan tiap-tiap titik data pada suatu kluster ditentukan oleh derajat keanggotaan (Bezdek, 1981). FCM adalah algoritma *clustering* yang memungkinkan setiap data *point* untuk memiliki derajat keanggotaan dalam lebih dari satu kluster. Dalam FCM, setiap kluster direpresentasikan oleh pusat kluster (μ_i), dan keanggotaan setiap titik data terhadap kluster dihitung menggunakan fungsi keanggotaan *fuzzy* (u_{ij}). Analisis *clustering* dengan menggunakan metode *Fuzzy C-Means* dapat dilakukan dengan langkah-langkah berikut.

1. Menentukan jumlah kluster (k), parameter *fuzziness* (m), dan fungsi keanggotaan awal (u_{ij}).
2. Dilakukan perhitungan pusat kluster berdasarkan fungsi keanggotaan.

$$\mu_i = \frac{\sum_{j=1}^n u_{ij}^m \cdot x_j}{\sum_{j=1}^n u_{ij}^m}$$

3. Dihitung fungsi keanggotaan baru menggunakan jarak antara data x_j dan pusat kluster μ_i .

$$u_{ij} = \frac{1}{\sum_{l=1}^k \left(\frac{\|x_j - \mu_l\|}{\|x_j - \mu_i\|} \right)^{\frac{2}{(m-1)}}}$$

4. Dilakukan iterasi dengan mengulang langkah 2 dan 3 hingga perubahan fungsi keanggotaan lebih kecil dari ambang batas tertentu atau iterasi maksimum tercapai.

Grey Wolf Optimimization (GWO)

Grey Wolf Optimization (GWO) adalah algoritma optimasi berbasis *metaheuristic* yang diperkenalkan oleh Mirjalili et al. pada tahun 2014. Algoritma ini terinspirasi oleh perilaku sosial dan strategi berburu serigala abu-abu (*Canis lupus*) di alam liar. GWO dirancang untuk menyelesaikan masalah optimasi non-linier dan multi-dimensi dengan efisiensi tinggi.

Proses optimasi dalam GWO terdiri dari tiga tahapan utama sebagai berikut

a. *Tracking, encircling, and attacking prey* (pelacakan, pengelilingan, dan penyerangan)

Serigala mengelilingi mangsa dengan model matematis sebagai berikut

$$D = \left| C \cdot X_p - X \right|$$
$$X(t + 1) = X_p - A \cdot D$$

Di mana D adalah jarak serigala terhadap mangsa, X_p adalah posisi mangsa, X adalah posisi serigala, serta A dan C adalah vektor koefisien yang dihitung secara dinamis.

b. *Leadership* (Kepemimpinan)

Tiga solusi terbaik (α, β, δ) memandu serigala lainnya untuk memperbarui posisinya. Formula untuk posisi baru serigala adalah sebagai berikut

$$X(t + 1) = \frac{X_1 + X_2 + X_3}{3}$$

Di mana X_1, X_2, X_3 adalah solusi yang dihitung berdasarkan posisi α, β, δ

c. *Hunting and attacking* (berburu dan menyerang)

Ketika parameter A mendekati nol, maka serigala melakukan eksploitasi intensif di sekitar mangsa.

Artificial Bee Colony (ABC)

Artificial Bee Colony (ABC) adalah algoritma optimasi yang dimulai dengan pencarian sumber makanan oleh lebah. Begitu lokasi nektar ditemukan, lebah pekerja (*Employed bee*) memberi tanda agar lebah pengamat (*Onlooker bee*) dapat memilih sumber terbaik. Sumber makanan yang habis akan ditinggalkan dan digantikan oleh lebah pengintai (*Scout bee*) yang mencari lokasi baru secara acak. Proses ini berulang hingga ditemukan sumber makanan terbaik (Karboga & Ozturk, 2009).

Posisi sumber makanan diperbarui menggunakan rumus

$$x_{ij} = l_{j,k} + rand(0, 1)(u_{j,k} - l_{j,k})$$

Dimana, $l_{j,k}$ dan $u_{j,k}$ adalah nilai batas bawah dan atas untuk tiap dimensi data, dan $rand(0,1)$ menghasilkan angka acak antara 0 dan 1.

Fitness dihitung menggunakan rumus

$$fit_i = \frac{1}{1+f_i}$$

$$f_i = \frac{1}{D_{Train}} \sum_{j=1}^{D_{Train}} d(x_j, p_i^{CL_{known}(x_j)})$$

Dimana, fit_i adalah fitness dari sumber makanan, f_i adalah fungsi biaya dari permasalahan kluster D_{Train} adalah jumlah banyaknya data, $p_i^{CL_{known}(x_j)}$ adalah mendefinisikan kelas instansi data, dan x_j adalah data ke-j.

Posisi sumber makanan kemudian diperbarui lebih lanjut untuk setiap employed bee dan onlooker bee dengan rumus:

$$v_{ij} = z_{ij} + \phi_{ij}(z_{ij} - z_{kj})$$

Dimana ϕ_{ij} adalah angka acak antara $\{-1, 1\}$, dan v_{ij} adalah kandidat posisi makanan baru berdasarkan posisi yang lama dalam memori. $k \in \{1, 2, \dots, SN\}$ dan $j \in \{1, 2, \dots, D\}$ adalah indeks yang dipilih acak, namun k harus berbeda indeks dengan i.

Setelah itu, onlooker bee mengevaluasi solusi berdasarkan probabilitas, dan solusi yang paling buruk digantikan dengan solusi baru yang acak:

$$z_i^j = z_{min}^j + rand(0, 1)(z_{max}^j - z_{min}^j)$$

Dimana, z_i Sumber makanan yang di tinggalkan onlooker bee dan $j \in \{1, 2, \dots, D\}$.

Proses ini diulang hingga mencapai Maximum Cycle Number (MCN) atau limit untuk ABCKM, yang dihitung dengan rumus Limit = SN X D. Sumber makanan optimal diperoleh dengan membandingkan nilai kecocokan dari semua sumber yang ada selama iterasi.

Particle Swarm Optimization (PSO)

Particle Swarm Optimization (PSO) adalah sebuah algoritma optimasi berbasis populasi yang terinspirasi oleh perilaku sosial dari organisme, seperti burung atau ikan. Algoritma ini pertama kali diperkenalkan oleh Russell C. Eberhart dan James Kennedy pada tahun 1995. PSO digunakan untuk menyelesaikan berbagai masalah optimasi dengan cara iteratif, di mana setiap solusi potensial diwakili oleh partikel dalam ruang pencarian.

PSO beroperasi dengan cara menyimulasikan perilaku kawanan. Setiap individu dalam kawanan, yang disebut sebagai partikel, bergerak dalam ruang pencarian berdasarkan dua informasi utama, yaitu posisi terbaik yang pernah dicapai oleh partikel itu sendiri (dikenal sebagai *personal best* atau *pBest*) dan posisi terbaik yang ditemukan oleh seluruh kawanan (dikenal sebagai *global best* atau *gBest*). Dengan memanfaatkan informasi ini, setiap partikel memperbarui posisinya dalam upaya untuk menemukan solusi optimal (Rizki & Nurlaili, 2020).

Setiap partikel dalam PSO memiliki dua parameter penting, yaitu kecepatan dan posisi. Kecepatan partikel menentukan arah dan jarak gerakan partikel dalam ruang pencarian. Pembaruan posisi partikel dilakukan dengan rumus berikut:

$$v_i^{t+1} = w \cdot v_i^t + c_1 \cdot r_1 \cdot (pBest - x_i^t) + c_2 \cdot r_2 \cdot (gBest - x_i^t)$$

$$x_i^{t+1} = x_i^t + v_i^{t+1}$$

Di mana v_i^t adalah kecepatan partikel ke- i pada iterasi t , x_i^t adalah posisi partikel ke- i pada iterasi t , w adalah bobot inersia yang mengontrol kontribusi kecepatan sebelumnya, c_1 dan c_2 adalah koefisien pembelajaran untuk $pBest$ dan $gBest$, serta r_1 dan r_2 adalah angka acak antara 0 hingga 1.

Proses optimasi dilakukan dalam beberapa iterasi. Pada setiap iterasi, setiap partikel mengevaluasi kinerjanya menggunakan fungsi *fitness* yang sesuai dengan masalah yang dihadapi. Jika posisi baru lebih baik daripada $pBest$, maka nilai tersebut akan diperbarui. Demikian pula, jika posisi baru lebih baik daripada $gBest$, maka nilai tersebut juga akan diperbarui. Proses ini berlanjut hingga mencapai kriteria penghentian tertentu, seperti jumlah iterasi maksimum atau tidak ada peningkatan signifikan dalam solusi.

Mean Variance Optimization

Mean Variance portfolio adalah pendekatan yang dikembangkan oleh Harry Markowitz pada tahun 1952 untuk membantu investor dalam mengoptimalkan portofolio investasi. Model ini berfokus pada trade-off antara risiko dan return, di mana investor berusaha untuk memaksimalkan pengembalian yang diharapkan sambil meminimalkan risiko. Dalam hal ini, mean merujuk pada rata-rata pengembalian yang diharapkan dari portofolio, sedangkan variance adalah ukuran risiko yang menunjukkan seberapa besar fluktuasi pengembalian dari nilai rata-ratanya. Untuk menghitung variansi dari portofolio yang terdiri dari beberapa saham adalah sebagai berikut.

$$\sigma_p^2 = \sum_{i=1}^n w_i^2 \sigma_i^2 + \sum_{i=1}^n \sum_{j=1, j \neq i}^n w_i w_j \sigma_{ij}$$

Di mana σ_p^2 adalah variansi portofolio, w_i adalah bobot investasi pada aset i , σ_i^2 adalah variansi pengembalian aset i , dan σ_{ij} adalah kovarians antara pengembalian aset i dan j .

Model Mean-Variance dapat dirumuskan sebagai berikut.

$$\frac{1}{2} w^T \Sigma w$$

$$s. t. w^T \mu = \rho$$

$$w^T \mathbf{1}_N = 1$$

Tujuan optimasi mean-variance adalah menemukan bobot w_i untuk memaksimalkan return yang diharapkan dengan risiko minimum atau meminimalkan risiko untuk tingkat return tertentu. Hasil optimasi mean-variance adalah menghasilkan efficient frontier, yaitu kurva yang menunjukkan kumpulan portofolio yang memberikan return maksimum untuk setiap tingkat risiko. Portofolio pada efficient frontier adalah portofolio yang optimal.

METODOLOGI

Data yang digunakan dalam penelitian ini mencakup saham dari tiga sektor, yaitu telekomunikasi (TLKM, EXCL, ISAT), migas (MDCA, PGAS, AALI), dan perbankan (BBCA, BBRI, BMRI). Data yang dianalisis adalah harga saham penutupan harian, karena harga penutupan dianggap paling representatif dalam mencerminkan kondisi pasar pada akhir perdagangan.

Periode data yang digunakan adalah selama 1 tahun, dari 24 November 2023 hingga 26 November 2024, untuk memberikan gambaran fluktuasi harga saham yang cukup lengkap dan dinamis. Data ini akan digunakan untuk menganalisis performa saham dari ketiga sektor melalui metode analisis kluster dan optimasi portofolio.

Software statistik yang digunakan pada penelitian ini adalah python. Berikut langkah-langkah yang dilakukan:

1. Mengumpulkan data harga penutupan saham harian dari tiga sektor, yaitu telekomunikasi (TLKM, EXCL, ISAT), migas (MDCA, PGAS, AALI), dan perbankan (BBCA, BBRI, BMRI) untuk 1 tahun, dari 24 November 2023 hingga 26 November 2024.
2. Menghitung nilai return untuk setiap saham perusahaan dengan rumus *Log Return*
3. Mendeskripsikan nilai pengembalian perusahaan tersebut. Data return dideskripsikan menggunakan statistika deskriptif.
4. Penentuan Jumlah Cluster Optimal dengan menggunakan Elbow Method untuk menentukan jumlah cluster optimal
5. Melakukan analisis Clustering menggunakan metode K-Means, GMM, dan FCM untuk mengelompokkan saham. Setiap cluster berisi saham dengan karakteristik return dan risiko yang serupa.
6. Pilih saham dengan rata-rata return tertinggi dari masing-masing cluster untuk membentuk portofolio yang terdiversifikasi
7. Melakukan analisis Optimasi Portofolio menggunakan metode ABC (Artificial Bee Colony), GWO (Grey Wolf Optimization), PSO (Particle Swarm Optimization), dan MVO (Mean Variance Optimization) untuk menentukan bobot investasi pada saham-saham yang dipilih, berdasarkan kinerja portofolio
8. Bandingkan performa portofolio dari masing-masing metode optimasi berdasarkan rata-rata return tahunan, volatilitas, dan Sharpe ratio.
9. Melakukan simulasi investasi dengan modal 1 milyar rupiah berdasarkan bobot portofolio untuk melihat keuntungan atau kerugian jangka pendek.
10. Evaluasi metode optimasi terbaik berdasarkan performa dari keempat metode optimisasi yang digunakan

HASIL DAN PEMBAHASAN

Statistik Deskriptif *Return*

Berdasarkan data harga saham, *return* dihitung menggunakan *log return* untuk setiap saham dalam periode yang dianalisis yang disajikan pada Tabel 1.

Tabel 1. Data Return Harga Saham

Tanggal	Saham								
	TLKM	ISAT	EXCL	PGAS	MEDC	AALI	BBRI	BMRI	BBCA
2023-11-27	0.01644	0.01093	0.00957	0.00438	-0.00893	0.01414	-0.00930	0.00425	-0.00562
2023-11-28	0.02416	-0.00545	0.02353	-0.01319	0.02655	0.01394	0.00000	0.00000	0.00000
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
2024-11-22	-0.00725	-0.02429	-0.01367	0.00000	0.00000	0.00404	0.03469	0.01613	0.00000
2024-11-25	-0.00364	0.02429	0.00458	0.04895	0.02160	0.00000	0.01578	0.05069	0.03246

Berdasarkan data *return* yang diperoleh, statistik deskriptif untuk masing-masing saham dihitung dan disajikan pada Tabel 2.


Tabel 2. Statistik Deskriptif Return Harga Saham

Saham	Rata-rata	Standar Deviasi
TLKM	-0.001170	0.017624
ISAT	0.000396	0.023307
EXCL	0.000217	0.020508
PGAS	0.001345	0.019130
MEDC	0.000165	0.025032
AALI	-0.000525	0.014614
BBRI	-0.000794	0.018136
BMRI	0.000473	0.018396
BBCA	0.000551	0.013410

Rata-rata return menunjukkan imbal hasil harian, di mana PGAS memiliki rata-rata return tertinggi (0.001345), sementara TLKM, AALI, dan BBRI memiliki return negatif, yang menunjukkan kerugian rata-rata. Standar deviasi, yang mencerminkan risiko atau fluktuasi harga, menunjukkan bahwa MEDC memiliki standar deviasi tertinggi (0.025032), menandakan pergerakan harga yang sangat besar dan lebih berisiko, sementara BBKA memiliki standar deviasi terendah (0.013410), menunjukkan kestabilan harga yang lebih baik. Informasi ini memberikan gambaran yang jelas tentang profil risiko dan imbal hasil setiap saham.

Penentuan Jumlah *Cluster* Optimal

Jumlah *cluster* optimal dalam analisis *clustering* dicari menggunakan *elbow method*.

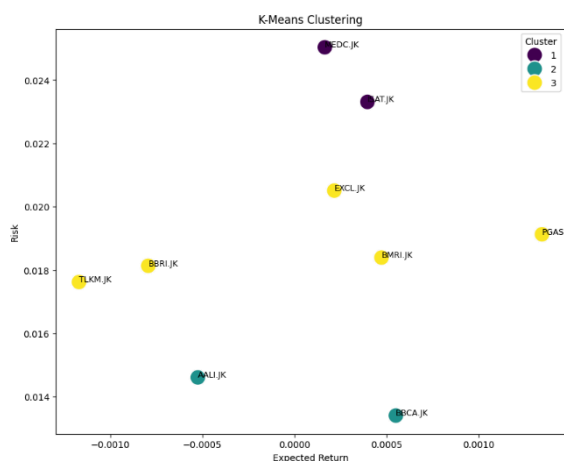


Gambar 1. Grafik Hasil *Elbow Method*

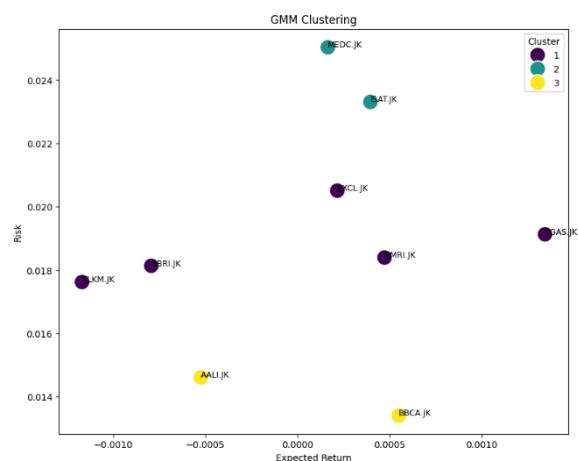
Grafik di atas menunjukkan hubungan antara jumlah cluster (k) dan inersia (*sum of squared distances*) yang dihitung untuk setiap k . Berdasarkan grafik tersebut, terlihat bahwa terjadi penurunan yang signifikan dalam nilai inersia antara $k = 2$ dan $k = 4$. Namun, setelah $k = 4$, penurunan inersia mulai melambat dan membentuk pola siku atau *elbow* yang jelas. Hal ini menunjukkan bahwa penambahan jumlah *cluster* lebih lanjut tidak memberikan pengurangan yang signifikan dalam inersia, berarti model *clustering* mulai stabil. Oleh karena itu, dapat disimpulkan bahwa jumlah *cluster* optimal untuk mengelompokkan data saham dalam analisis ini adalah 3.

Analisis *Clustering*

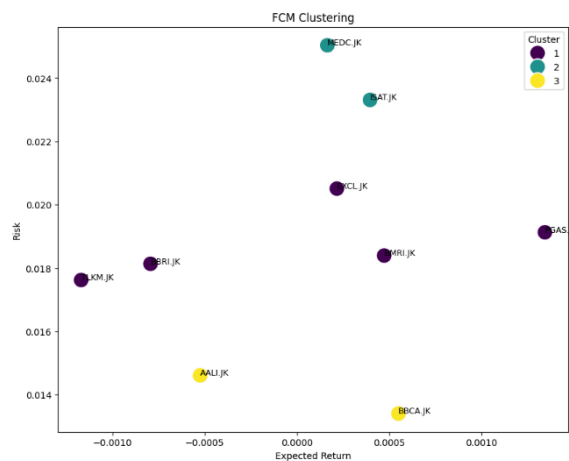
Dalam penelitian ini, dilakukan *clustering* terhadap sembilan saham berdasarkan rata-rata *return* dan standar deviasi *return* untuk mengelompokkan saham ke dalam tiga *cluster* yang berbeda. Tiga metode *clustering* yang digunakan adalah K-Means, *Gaussian Mixture Model* (GMM), dan *Fuzzy C-Means* (FCM). Hasil *clustering* dari masing-masing metode disajikan dalam Gambar 2 hingga Gambar 4.



Gambar 2. Hasil *Clustering* K-Means



Gambar 3. Hasil *Clustering* GMM



Gambar 4. Hasil *Clustering* FCM

Dari ketiga gambar tersebut, terlihat bahwa meskipun pemberian label *cluster* berbeda antara ketiga metode, anggota dari masing-masing *cluster* adalah sama. Baik GMM maupun FCM memberikan label *cluster* yang serupa, sementara K-Means menghasilkan label yang berbeda. Setelah dilakukan penyesuaian dan penyamaan label *cluster*, hasil *clustering* dari ketiga metode kemudian diringkas dalam Tabel 3.

Tabel 3. Ringkasan Hasil *Clustering*

Cluster	Anggota
1	TLKM, BBRI, EXCL, BMRI, PGAS
2	MEDC, ISAT
3	AALI, BBKA

Setiap anggota dalam suatu *cluster* memiliki karakteristik yang serupa, yang membedakannya dari anggota *cluster* lain. *Cluster* 1 terdiri dari saham-saham seperti TLKM, BBRI, EXCL, BMRI, dan PGAS, yang memiliki standar deviasi *return* yang sedang atau menengah. *Cluster* 2, yang terdiri dari MEDC dan ISAT, memiliki standar deviasi tinggi, menunjukkan fluktuasi yang lebih besar dalam *return* saham tersebut. Sementara itu, *cluster* 3 yang berisi AALI dan BBKA memiliki standar deviasi yang rendah, menunjukkan kestabilan *return* yang lebih tinggi.

Untuk membentuk portofolio yang optimal, diambil satu saham dengan rata-rata *return* tertinggi dari masing-masing *cluster*. Dari *cluster* 1, PGAS dipilih, sedangkan dari *cluster* 2, ISAT dipilih, dan dari *cluster* 3, BBKA dipilih. Menariknya, saham-saham yang terpilih ini secara kebetulan juga mewakili sektor-sektor yang berbeda. PGAS mewakili sektor migas, ISAT mewakili sektor telekomunikasi, dan BBKA mewakili sektor perbankan. Dengan demikian, meskipun pemilihan saham didasarkan pada kriteria rata-rata *return* tertinggi dalam masing-masing *cluster*, saham-saham yang terpilih juga secara tidak langsung mencerminkan diversifikasi sektor yang penting dalam manajemen portofolio.

Pembentukan Portofolio Optimal

Ketiga saham terpilih digunakan untuk membentuk portofolio optimal. Untuk menentukan bobot investasi dari masing-masing saham, digunakan tiga metode optimasi, dengan tiga di

antaranya berbasis *metaheuristic*, yaitu *Ant Bee Colony* (ABC) *Optimization*, *Grey Wolf Optimization* (GWO), dan *Particle Swarm Optimization* (PSO). Sebagai pembanding, digunakan juga metode konvensional *Mean Variance Optimization* (MVO). Tabel 4 di bawah ini menunjukkan hasil perhitungan bobot saham dalam portofolio optimal serta performa yang tercapai untuk masing-masing metode optimasi. Performa portofolio diukur berdasarkan rata-rata *return* tahunan, volatilitas *return* tahunan, dan *sharpe ratio*.

Tabel 4. Bobot dan Performa Portofolio Optimal

Metode Optimasi	Saham	Bobot (%)	Performa Portofolio		
			Rata-rata <i>Return</i> Tahunan (%)	Volatilitas <i>Return</i> Tahunan (%)	<i>Sharpe Ratio</i>
ABC	PGAS	79.329	28.22	23.89	0.8934
	ISAT	0			
	BBCA	0.2067			
GWO	PGAS	18.037	13.89	27.92	0.2514
	ISAT	72.980			
	BBCA	0.898			
PSO	PGAS	66.2758	25.73	20.88	0.9031
	ISAT	0.3510			
	BBCA	33.3732			
MVO	PGAS	64.7603	25.45	20.57	0.9033
	ISAT	0.0009			
	BBCA	35.2388			

Berdasarkan tabel di atas, dapat dilihat bahwa metode ABC memberikan bobot investasi terbesar pada saham PGAS (79.329%) dengan rata-rata *return* tahunan yang cukup tinggi, yaitu 28.22%, yang selaras dengan volatilitas *return* tahunan yang tinggi, yakni 23.89%. Meskipun demikian, *sharpe ratio* yang diperoleh juga cukup tinggi, yaitu sebesar 0.8934, yang menunjukkan bahwa portofolio ini memiliki kinerja yang cukup baik dalam hal imbal hasil yang disesuaikan dengan risiko.

Di sisi lain, GWO menempatkan bobot terbesar pada saham ISAT (72.980%) dengan rata-rata *return* tahunan yang jauh lebih rendah, hanya 13.89%, dengan volatilitas *return* tahunan yang tinggi, yaitu 27.92%. Hal ini menyebabkan *sharpe ratio* portofolio GWO menjadi yang terendah, yaitu sebesar 0.2514, yang menandakan bahwa walaupun portofolio ini memiliki imbal hasil yang lebih rendah, risikonya relatif lebih tinggi dibandingkan dengan portofolio lainnya.

Sementara itu, PSO memberikan sebagian besar bobot pada saham PGAS (66.2758%) dengan rata-rata *return* tahunan yang tinggi, yaitu sebesar 25.73%, disertai dengan volatilitas *return* tahunan yang lebih rendah dibandingkan dengan metode ABC, yaitu sebesar 20.88%. *Sharpe ratio* PSO sebesar 0.9031 menunjukkan kinerja portofolio yang sangat baik dalam hal imbal hasil relatif terhadap risiko.

Sedangkan metode MVO, yang lebih konvensional, menempatkan bobot terbesar pada saham PGAS (64.7603%). Dengan rata-rata *return* tahunan sebesar 25.45% dan volatilitas *return*

tahunan yang serupa dengan PSO, yakni 20.57%, diperoleh *sharpe ratio* sebesar 0.9033. Ini menunjukkan performa yang hampir setara dengan PSO, meskipun dengan pendekatan yang lebih sederhana.

Dari hasil yang diperoleh, metode PSO dan MVO menunjukkan performa portofolio yang hampir serupa, keduanya memiliki *sharpe ratio* yang sangat baik, dengan MVO sedikit lebih unggul. Meskipun demikian, ABC juga menghasilkan portofolio dengan performa yang cukup baik, namun penempatan bobot yang sangat tinggi pada saham PGAS menunjukkan bahwa metode ini lebih terfokus pada satu saham. Hal ini berpotensi meningkatkan risiko karena kurangnya diversifikasi. Sebaliknya, GWO menunjukkan performa terendah yang mengindikasikan bahwa metode ini kurang efektif dalam mengelola risiko dibandingkan dengan metode lainnya.

Simulasi Investasi

Sebagai ilustrasi, dilakukan simulasi investasi jangka pendek untuk mengukur potensi keuntungan atau kerugian dari masing-masing portofolio. Seorang investor dengan modal sebesar 1 milyar rupiah berinvestasi pada portofolio yang terdiri dari tiga saham, yaitu PGAS, ISAT, dan BBKA. Saham-saham tersebut dibeli pada tanggal 26 November 2024 dan dijual pada tanggal 6 Desember 2024, dengan transaksi pembelian dan penjualan yang dilakukan berdasarkan harga saham penutupan pada masing-masing hari transaksi. Tabel 5 menunjukkan alokasi modal yang berbeda berdasarkan bobot dari masing-masing metode optimasi.

Tabel 5. Alokasi Modal

Saham	Alokasi (Rp)			
	ABC	GWO	PSO	MVO
PGAS	793.289.535	180.365.570	662.757.740	647.601.150
ISAT	0	729.801.560	3.508.720	9.760
BBKA	206.710.000	89.830.000	333.730.000	352.380.000
Sisa	465	2.870	3.540	9.090

Dari tabel di atas, dapat dilihat bahwa alokasi modal untuk PGAS paling dominan dari metode ABC, PSO, dan MVO. Sementara itu, ISAT memperoleh alokasi terbesar dari metode GWO dan BBKA menerima alokasi modal yang cukup besar dari portofolio PSO dan MVO. Sisa modal yang tidak terpakai setelah pembagian alokasi cukup kecil jumlahnya. Ini menunjukkan bahwa modal telah dialokasikan dengan sangat efisien dan sebagian besar dana digunakan untuk membeli saham sesuai dengan bobot yang ditentukan oleh masing-masing metode, sehingga dapat memaksimalkan potensi imbal hasil dari portofolio tersebut.

Keuntungan atau kerugian yang diperoleh dari investasi portofolio berdasarkan metode optimasi yang berbeda selama periode investasi dapat dilihat pada Tabel 6.

Tabel 6. Keuntungan atau Kerugian Investasi

Tanggal	Keuntungan/Kerugian (Rp)			
	ABC	GWO	PSO	MVO
2024-11-28	2.584.005	-20.349.420	2.058.160	2.109.170

2024-11-29	-7.752.015	-13.726.490	-6.533.980	-6.328.510
2024-12-02	12.920.285	-16.079.120	6.682.210	5.956.410
2024-12-03	29.974.250	28.608.630	28.363.460	28.142.380
2024-12-04	35.142.260	44.738.600	32.753.000	32.361.480
2024-12-05	23.255.785	33.277.230	23.584.410	23.576.010
2024-12-06	48.062.415	29.194.845	41.448.015	40.613.190

Secara keseluruhan, meskipun terdapat fluktuasi dalam hasil harian, portofolio yang menggunakan metode ABC menunjukkan performa yang unggul dalam hal keuntungan total, diikuti oleh PSO dan MVO. Sementara itu, GWO memberikan keuntungan yang lebih rendah dan cenderung tidak stabil. Hasil ini memberikan gambaran tentang bagaimana volatilitas pasar mempengaruhi performa portofolio yang dibentuk menggunakan berbagai metode optimasi.

KESIMPULAN

Berdasarkan hasil analisis klustering menggunakan tiga metode (*K-Means*, GMM, dan FCM), saham dikelompokkan menjadi tiga klaster dengan karakteristik risiko dan imbal hasil yang berbeda. Pemilihan saham untuk portofolio optimal didasarkan pada imbal hasil tertinggi dari setiap klaster, yaitu PGAS, ISAT, dan BBKA.

Metode optimasi portofolio PSO dan MVO menunjukkan kinerja terbaik dengan nilai Sharpe ratio yang tinggi, yang mengindikasikan efisiensi dalam mengelola risiko dan imbal hasil. Metode ABC, meskipun menghasilkan portofolio dengan imbal hasil yang baik, cenderung lebih fokus pada satu saham (PGAS), sehingga kurang terdiversifikasi. Di sisi lain, GWO memberikan kinerja yang lebih rendah dan fluktuatif. Pada Simulasi investasi menunjukkan bahwa portofolio yang dioptimalkan menggunakan PSO dan MVO menghasilkan keuntungan yang lebih stabil dan signifikan, sementara GWO cenderung memberikan hasil yang kurang menguntungkan. Dengan demikian, dapat disimpulkan bahwa PSO dan MVO lebih efektif dalam membentuk portofolio dengan risiko terkontrol dan imbal hasil optimal.

DAFTAR PUSTAKA

- Anugrahayu, M., & Azmi, U. (2023). Stock portfolio optimization using mean-variance and mean absolute deviation model based on K-medoids clustering by dynamic time warping. *Jurnal Matematika, Statistika Dan Komputasi*, 20(1), 164–183. <https://doi.org/10.20956/j.v20i1.27755>
- F. Farkhati, A. Hoyyi, and Y. Wilandari, "ANALISIS PEMBENTUKAN PORTOFOLIO OPTIMAL SAHAM DENGAN PENDEKATAN OPTIMISASI MULTIOBJEKTIF UNTUK PENGUKURAN VALUE AT RISK," *Jurnal Gaussian*, vol. 3, no. 3, pp. 371-380, Aug. 2014. <https://doi.org/10.14710/j.gauss.3.3.371-380>
- Jatnika, N. S., & Nababan, E. S. (2022). Optimisasi multiobjektif Dalam Pembentukan Portofolio Optimal saham dengan pengukuran value at risk (VAR). *Journal of*

Fundamental Mathematics and Applications (JFMA), 5(1), 52–66.
<https://doi.org/10.14710/jfma.v5i1.14662>

- Lestari, V., Kamsyakawuni, A., & Santoso, K. A. (2019). Implementasi algoritma grey wolf optimizer (GWO) di toko citra tani jember. *Majalah Ilmiah Matematika Dan Statistika*, 19(2), 65. <https://doi.org/10.19184/mims.v19i2.17269>
- L. Gubu, E. Cahyono, A. Arman, H. Budiman, and M. K. Djafar, "OPTIMASI PORTOFOLIO MEAN-VARIANCE DENGAN ANALISIS KLASSTER FUZZY C-MEANS," *Jurnal Gaussian*, vol. 12, no. 4, pp. 593-604, Jul. 2024. <https://doi.org/10.14710/j.gauss.12.4.593-604>
- Mardhiyah, A. (2017). Peranan analisis return Dan Risiko Dalam Investasi. *JURNAL EKONOMI DAN BISNIS ISLAM*, 2(1). <https://doi.org/10.32505/jebis.v2i1.120>
- Rafulta, E. R., & Putra, R. T. (2020). Analisis portofolio optimal : Pendekatan mean variance pada harga Komoditas Pangan di Kota Padang. *Jurnal Ilmiah Poli Rekayasa*, 15(2), 48. <https://doi.org/10.30630/jipr.15.2.166>
- Rizki, A. M., & Nurlaili, A. L. (2020). Algoritme Particle Swarm Optimization (PSO) untuk Optimasi Perencanaan Produksi Agregat Multi-Site pada Industri Tekstil Rumahan. *Jurnal Kemajuan Teknik Komputer, Elektro, & Telekomunikasi*, 1(2). <https://doi.org/10.52435/complete.v1i2.73>
- Rolanda, I., & Kurniasih, A. (2015). Analisis Portofolio Optimal : Pendekatan Mean Variance (Studi Kasus pada Dana Pensiun Lembaga Keuangan Muamalat).
- Subkhi, M. B., Fatichah, C., & Zaenal Arifin, A. (2023). Seleksi fitur menggunakan hybrid binary grey wolf optimizer Untuk Klasifikasi Hadist Teks arab. *Jurnal Teknologi Informasi Dan Ilmu Komputer*, 10(5), 1115–1122. <https://doi.org/10.25126/jtiik.2023106375>